

VALIDADOR DOCUMENTAL



Manual de Usuario — v2.0

Programa de Fortalecimiento Empresarial

Tabla de Contenido

1.	Descripcion General del Sistema	3
2.	Requisitos e Instalacion	4
3.	Arranque del Servidor	5
4.	Uso desde Swagger UI — Paso a Paso	5
5.	Flujos de Validacion (00 al 03)	8
6.	Estructura del Archivo de Entrada	10
7.	Checklist de Salida	11
8.	Ejecucion de Flujos Independientes	12
9.	Filas Pendientes por Timeout	13
10.	Variables de Entorno	14
11.	Preguntas Frecuentes	15

1. Descripcion General del Sistema

El **Validador Documental** es una aplicacion web desarrollada en **FastAPI** que automatiza la verificacion de la documentacion de beneficiarios almacenada en **Microsoft SharePoint**. El sistema recibe un archivo Excel con la matriz de registros, descarga selectivamente las carpetas de cada beneficiario y produce un checklist de validacion en Excel con el estado de cada documento.

ENTRADA	PROCESO	SALIDA
Matriz Excel (beneficiarios)	Descarga SharePoint Validacion documentos Analisis IA (opcional)	Checklist Excel + Pendientes si hay timeouts

Figura 1. Flujo general del sistema.

Carpetas validadas por beneficiario:

00	Documentacion	Cedula, RUT, Comercio, Tenencia segun modalidad
01	Visita 1 — Caracterizacion	Acta compromiso, acta visita, fotos/videos, tratamiento datos, gestor
02	Visita 2 — Diagnostico	Acta visita 2, diagnostico empresarial, plan de negocio
03	Capacitacion	Encuestas, lista grupal, reporte individual, modulos TX/RX

2. Requisitos e Instalacion

Requisitos previos:

- Python 3.10 o superior
- Acceso a internet (para descargas de SharePoint y OpenAI)
- Archivo Excel de la matriz de beneficiarios

1 Clonar o descomprimir el proyecto

Ubique la carpeta **validador_documental** en su equipo.

2 Crear el entorno virtual

```
python -m venv .venv  
.venv\Scripts\activate
```

3 Instalar dependencias

```
pip install -r requirements.txt
```

4 Configurar variables de entorno

```
copy .env.example .env
```

Edite el archivo **.env** con su API Key de OpenAI si desea activar el analisis con IA.

3. Arranque del Servidor

Desde la carpeta del proyecto, ejecute:

```
python server.py
```

Servidor basico	python server.py	Produccion / uso normal
Recarga automatica	python server.py --reload	Desarrollo (recarga al cambiar codigo)
Puerto personalizado	python server.py --port 9000	Cuando el puerto 8000 esta ocupado

OK: El servidor estara disponible en <http://127.0.0.1:8000> — abra esta URL en su navegador para acceder a Swagger UI.

4. Uso desde Swagger UI — Paso a Paso

Swagger UI es la interfaz web integrada que permite ejecutar todos los endpoints sin necesidad de Postman ni código adicional. Acceda a:

<http://127.0.0.1:8000/docs>

Metodo	Endpoint	Que hace
GET	/health	Verifica que el servidor esta activo
POST	/validacion/validar	Sube la matriz e inicia la validacion
GET	/validacion/estado/{job_id}	Consulta el progreso del trabajo
GET	/validacion/resultado/{job_id}	Descarga el checklist Excel resultante
GET	/validacion/pendientes/{job_id}	Descarga las filas que fallaron por timeout
POST	/descarga/descargar	Prueba la conexion con una URL de SharePoint

1 Verificar que el servidor esta activo

Expanda **GET /health** → clic en **Try it out** → **Execute**

Respuesta esperada:

```
{ "status": "ok", "version": "2.0.0" }
```

2 Lanzar la validacion — POST /validacion/validar

1. Expanda **POST /validacion/validar** → clic en **Try it out**
2. En el campo **archivo** → clic en **Choose File** → seleccione el Excel de la matriz
3. En el campo **flujos** escriba los flujos a ejecutar (dejar vacio para todos):

Todo el flujo completo	(dejar vacio)
Solo documentacion	00
Solo primera visita	01
Documentacion + visita 1	00,01
Las dos visitas	01,02
Todo excepto capacitacion	00,01,02

4. Clic en **Execute**
5. Copie el **job_id** de la respuesta — lo necesitara en los siguientes pasos:

```
{ "job_id": "a1b2c3d4-...", "estado": "iniciado", "flujos": ["00", "01", "02", "03"] }
```

AVISO: El proceso corre en background. La respuesta llega en menos de 1 segundo aunque la validacion tarde varios minutos.

3 Consultar el progreso — GET /validacion/estado/{job_id}

1. Expanda **GET /validacion/estado/{job_id}** → Try it out
2. Pegue el **job_id** copiado en el paso anterior
3. Clic en **Execute** — repita hasta que **estado** sea **completado**

iniciado	Job registrado, aun no comenzo a procesar filas
procesando	Validando filas — vea filas_procesadas / filas_total
completado	Todas las filas procesadas — checklist disponible
error	Falla critica (archivo invalido, SharePoint caído)

4 Descargar el checklist — GET /validacion/resultado/{job_id}

1. Expanda **GET /validacion/resultado/{job_id}** → Try it out
2. Pegue el **job_id**
3. Clic en **Execute**
4. En la seccion **Response body**, haga clic en **Download file**
5. Guarde el archivo **checklist_validacion.xlsx**

INFO: Solo disponible cuando el estado es 'completado'. Si se llama antes, retorna HTTP 400.

5 Verificar filas pendientes — GET /validacion/pendientes/{job_id}

Si alguna fila fallo por timeout o error de red, el campo **filas_omitidas** en /estado sera mayor que 0.

1. Expanda **GET /validacion/pendientes/{job_id}** → Try it out
2. Pegue el **job_id** → **Execute**
3. Descargue **pendientes_reintento.xlsx**
4. Suba ese archivo como nueva matriz para reprocesar solo las filas fallidas.

OK: Si no hubo filas pendientes, este endpoint retorna HTTP 404 — es normal.

5. Flujos de Validacion — Detalle por Carpeta

Carpeta 00 — Documentacion

Documento	M1	M2	M3	M4
CEDULA	Obligatorio	Obligatorio	Obligatorio	Obligatorio
COMERCIO	No aplica	Opcional	Obligatorio	Obligatorio
RUT	Opcional	Opcional	Obligatorio	Obligatorio
TENENCIA	Opcional	Obligatorio	Obligatorio	Obligatorio

Carpeta 01 — Visita 1 — Caracterizacion

Documento	Requerido	Que verifica la IA
ACTA_COMPROMISO	Si	Firmas y fechas correctas
ACTA_VISITA_1	Si	Extrae nombre y cedula del gestor
TRATAMIENTO_DATOS	Si	Autorizacion firmada presente
Fotos / Videos	Min. 4	Conteo de archivos multimedia
GESTOR	Si	Verifica gestor en base de datos interna

Carpeta 02 — Visita 2 — Diagnostico

Documento	Requerido	Que verifica la IA
ACTA_VISITA_2	Si	Contenido y firmas del acta
DIAGNOSTICO	Si	Documento completo y coherente
PLAN_NEGOCIO	Si	Campos obligatorios completados

Carpeta 03 — Capacitacion

Elemento	Descripcion
Encuestas	Archivos ENCUESTA_XXXXX — uno por participante
GRUPAL	Lista de asistencia grupal del modulo
Individual	Reporte ID_ / Formacion / Cumplimiento por asistente
Modulos TX/RX	Archivos T{n}_R{n}_... — lista de asistencia por modulo
Asistencia IA	GPT-4.1 verifica nombres de encuestas en TX_RX

6. Estructura del Archivo de Entrada (Matriz)

El archivo Excel de entrada debe tener una hoja activa con las siguientes columnas. Los nombres deben coincidir exactamente (sensible a mayúsculas).

ID_unico	Si	Identificador unico del beneficiario
modalidad	Si	M1, M2, M3 o M4
unidad_doc	Si	Numero de cedula o NIT del beneficiario
carpetas_link	Si	URL anonima de la carpeta en SharePoint
integrante_nombre1	No	Primer nombre del integrante
integrante_nombre2	No	Segundo nombre del integrante
integrante_apellido1	No	Primer apellido del integrante
integrante_apellido2	No	Segundo apellido del integrante

AVISO: La columna carpetas_link debe contener la URL de la carpeta raiz del beneficiario en SharePoint, no la URL de una subcarpeta especifica. El sistema busca automaticamente las subcarpetas 00, 01, 02 y 03.

INFO: El proceso es reanudable: si se interrumpe, al volver a ejecutar con el mismo archivo de salida continua desde donde quedo, saltando los ID_unico ya procesados.

7. Checklist de Salida — Interpretacion

El checklist Excel de salida tiene una fila por beneficiario y columnas agrupadas por carpeta. Los encabezados de grupo usan colores para identificar cada seccion.

Identificacion (azul)	ID_unico, modalidad, unidad_doc
00 Documentacion (naranja)	CEDULA, COMERCIO, RUT, TENENCIA
01 Visita (verde oscuro)	01_DOCUMENTOS, 01_FOTOS_VIDEOS, ACTA_COMPROMISO, ACTA_VISITA, G
02 Visita 2 (morado)	02_DOCUMENTOS, 02_ACTA_VISITA, 02_DIAGNOSTICO, 02_PLAN_NEGOCIO
03 Capacitacion (teal/verde)	03_ENCUESTAS, 03_GRUPAL, 03_INDIVIDUAL, 03_MODULOS, 03_ASISTENCIA
General (gris)	observaciones

Significado de los valores en las celdas:

OK	Documento obligatorio presente	Sin color
FALTA (obligatorio)	Documento obligatorio ausente	Rojo
Presente	Documento opcional encontrado	Sin color
Ausente	Documento opcional no encontrado	Sin color
N/A	No aplica para esta modalidad	Sin color
—	Flujo no ejecutado (seleccion parcial)	Sin color
ALERTA: ...	La IA detecto un problema en el doc.	Amarillo
NO REGISTRADO — ...	El gestor no esta en la base de datos	Rojo

8. Ejecucion de Flujos Independientes

El sistema permite ejecutar uno o varios flujos de validacion sin necesidad de procesar todas las carpetas. Esto es util cuando solo se requiere verificar un aspecto especifico de la documentacion o cuando se quiere reutilizar el resultado de una ejecucion anterior.

INFO: Las columnas de los flujos no ejecutados apareceran con el valor '—' en el checklist, indicando que no fueron evaluadas en esa ejecucion.

Todo el flujo completo	(dejar vacio)
Solo documentacion	00
Solo primera visita	01
Solo segunda visita	02
Solo capacitacion	03
Documentacion + primera visita	00,01
Las dos visitas	01,02
Todo excepto capacitacion	00,01,02
Documentacion + capacitacion	00,03

AVISO: Caso de uso tipico: ejecutar primero '00,01' para validar documentacion basica. Cuando esten listas las visitas 2 y capacitacion, ejecutar '02,03' sobre la misma matriz — el sistema retomara sin repetir los IDs ya procesados.

9. Filas Pendientes por Timeout o Error de Red

Cuando una fila no puede procesarse por problemas de conectividad con SharePoint (timeout, error de red, servidor no disponible), el sistema la omite, continua con la siguiente fila y al finalizar genera un archivo **pendientes_reintento.xlsx** con las filas que no se ejecutaron.

Timeout durante descarga	Omite la fila, limpia temporales, pasa a la siguiente
Error de red / conexion	Igual que timeout — registra en log y continua
Error critico inesperado	Omite la fila — no detiene el job completo
Al finalizar con omisiones	Genera pendientes_reintento.xlsx en la carpeta del job
Campo filas_omitidas en /estado	Indica cuantas filas fueron omitidas

Como reprocesar las filas pendientes:

1 Verificar que hay pendientes

En **GET /validacion/estado/{job_id}** revise el campo **filas_omitidas**. Si es 0, no hay pendientes.

2 Descargar pendientes_reintento.xlsx

Ejecute **GET /validacion/pendientes/{job_id}** y descargue el archivo.

3 Subir como nueva matriz

Suba **pendientes_reintento.xlsx** como archivo de entrada en un nuevo **POST /validacion/validar**.

4 Combinar checklists

El nuevo checklist contendrá solo los beneficiarios pendientes. Puede combinar ambos archivos Excel manualmente.

10. Variables de Entorno (.env)

Copie **.env.example** a **.env** y ajuste los valores segun su entorno. Todas las variables tienen valores por defecto funcionales — solo es obligatorio configurar **OPENAI_API_KEY** si desea activar el analisis con IA.

JOBS_DIR	jobs	Directorio donde se guardan los trabajos y resultados
DOWNLOADS_DIR	descargas_sharepoint	Directorio temporal de descargas de SharePoint
MAX_WORKERS_LISTADO	8	Hilos paralelos para listar carpetas en SharePoint
MAX_WORKERS_DESCARGA	12	Hilos paralelos para descargar archivos
CHECKLIST_LOTE_GUARDADO	50	Numero de filas antes de guardar el checklist a disco
TIMEOUT_DESCARGA	120	Segundos maximos de espera por archivo de SharePoint
IA_HABILITADO	false	Activa el analisis semantico con OpenAI (true/false)
OPENAI_API_KEY	(vacio)	API Key de OpenAI — requerida si IA_HABILITADO=true
OPENAI_MODEL	gpt-4o	Modelo OpenAI para analisis visual de documentos

INFO: Para activar el analisis con IA, configure IA_HABILITADO=true y proporcione su OPENAI_API_KEY. El modelo gpt-4o analiza visualmente los documentos escaneados para verificar firmas, fechas y contenido.

11. Preguntas Frecuentes

P: El endpoint /resultado retorna HTTP 400

R: El job aun no ha terminado. Consulte /estado y espere a que el estado sea 'completado'.

P: Aparece 'N/A' en todas las columnas de un flujo

R: La carpeta correspondiente no fue encontrada en SharePoint para ese beneficiario. Verifique que la URL en carpetas_link sea correcta y que la carpeta exista.

P: Aparece '—' en las columnas de un flujo

R: Ese flujo no fue incluido en la ejecucion. Use el campo 'flujos' en Swagger para incluirlo, o deje el campo vacio para ejecutar todos.

P: Sale 'Error IA (ver log)' en una columna de revision

R: Ocurrio un error al comunicarse con OpenAI. Verifique su OPENAI_API_KEY y conexion a internet. Revise el log del servidor para el detalle del error.

P: El proceso se queda pegado en una fila

R: SharePoint puede tardar o no responder. El sistema tiene un timeout de 120 segundos por archivo — pasado ese tiempo, omite la fila y la incluye en pendientes_reintento.xlsx.

P: Como reprocesar solo algunos beneficiarios

R: Cree un Excel con solo las filas que desea reprocesar y subalo como nueva matriz. Si ya fueron procesados en un checklist anterior, use un archivo de salida diferente.

P: El gestor aparece como 'NO REGISTRADO'

R: La IA extrajo el nombre o cedula del gestor del acta de visita, pero no coincide con ningun registro en la base de datos interna. Verifique el documento y la base de gestores.